

Parte A:

Frase: EL banco aguanta

1) Entrada

Calculamos $X = E + P$ Para cada palabra:

$$X_{El} = (0, 0, 0, 1) + (0, 0, 0, 0)$$

$$X_{EL} = (0, 0, 0, 1)$$

Hacemos la suma para los demás

$$X_{banco} = (1, 1, 0, 1)$$

$$X_{aguanta} = (1, 0, 1, 2)$$

Matriz de entrada final:

$$X = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

Sumamos el embedding para cada palabra (E) con el de su posición (P) para que el transformer tenga información tanto del significado de cada palabra como de su lugar en la frase.

2) Proyecciones

Calculamos 3 matrices:

Q (query): qué información busca cada palabra en los demás

K (key): qué características ofrece cada palabra para que las otras puedan encontrarla.

V (value): qué información aporta cada palabra cuando recibe atención.

Calculamos Q

$$Q = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Como multiplicar por la identidad no cambia los valores;

$$Q = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \quad Q = X$$

Proyectamos los embeddings a consultas (a) para representar que información busca cada token.

Calculamos k

$$k = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

C.A

$$(0, 0, 0, 1) \cdot W_k = (0, 0, 0, 0) \quad (E)$$

$$(1, 1, 0, 1) \cdot W_k = (1, 1, 0, 0) \quad (\text{banco})$$

$$1 \cdot 1 + 0 \cdot 0 + 1 \cdot 1 + 2 \cdot 0 = 2 \quad (\text{Aguarra})$$

$$1 \cdot 0 + 0 \cdot 1 + 1 \cdot 1 + 2 \cdot 0 = 1$$

Tercera y cuarta componente: ambas son 0, porque las últimas dos columnas de W_k contienen ceros.

$$(1, 0, 1, 2) \cdot W_k = (2, 1, 0, 0)$$

Matriz k Final:

$$k = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{pmatrix}$$

Multiplicamos x por W_k para obtener las claves de cada palabra. Estas claves se compararán con las consultas Q para medir afinidad entre tokens.

Calculamos $V = X \cdot W_v$

Como W_v es identidad

$V = X$

$$V = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \quad \text{Calculamos } V \text{ para obtener la información que cada token puede aportar a los demás durante la atención.}$$

(3) Afinidades

Calculamos k^T

$$k^T = \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Multiplcamos Q por k^T

$$S = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

Primera fila: El

$$S_{11} = 0 \cdot 0 + 0 \cdot 0 + 0 \cdot 0 + 1 \cdot 0 = 0$$

$$S_{12} = 0 \cdot 1 + 0 \cdot 1 + 0 \cdot 0 + 1 \cdot 0 = 0$$

$$S_{13} = 0 \cdot 2 + 0 \cdot 1 + 0 \cdot 0 + 1 \cdot 0 = 0$$

(0,0,0)

Segunda fila: banco

$$S_{21} = 1 \cdot 0 + 1 \cdot 0 + 0 \cdot 0 + 1 \cdot 0 = 0$$

$$S_{22} = 1 \cdot 1 + 1 \cdot 1 + 0 \cdot 0 + 1 \cdot 0 = 2$$

$$S_{23} = 1 \cdot 2 + 1 \cdot 1 + 0 \cdot 0 + 1 \cdot 0 = 3$$

(0,2,3)

Tercera fila: Aguanta

$$S_{31} = 1 \cdot 0 + 0 \cdot 0 + 1 \cdot 0 + 2 \cdot 0 = 0$$

$$S_{32} = 1 \cdot 1 + 0 \cdot 1 + 1 \cdot 0 + 2 \cdot 0 = 1$$

$$S_{33} = 1 \cdot 2 + 0 \cdot 1 + 1 \cdot 0 + 2 \cdot 0 = 2$$

(0,1,2)

$$S = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

Multiplicamos Q por k^T para calcular los productos punto entre las consultas y las claves de cada palabra. Estos valores representan las afinidades que se utilizarán para determinar los pesos de atención.

④ Escala

$$\frac{S}{\sqrt{d}} \quad d=4$$

$$\sqrt{4}=2$$

$$\frac{S}{2} = \begin{pmatrix} 0/2 & 0/2 & 0/2 \\ 0/2 & 2/2 & 3/2 \\ 0/2 & 1/2 & 2/2 \end{pmatrix}$$

$$\frac{S}{\sqrt{d}} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,500 \\ 0 & 0,500 & 1 \end{pmatrix}$$

Dividimos la matriz de afinidades S por la raíz cuadrada de la dimensión de los vectores ($\sqrt{4}=2$) para controlar la magnitud de los valores antes de aplicar softmax y evitar que las probabilidades queden demasiado concentradas.

⑤ Máscara causal

Primera fila (EI)

EI no puede mirar a baño ni a gusano. Preemplazamos con $-\infty$
 $(0, -\infty, -\infty)$

Segunda fila : baño $(0, 1, -\infty)$

Tercera fila (gusano): $(0, 0,500, 1)$

$$S_{\text{máscara}} = \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0,500 & 1 \end{pmatrix}$$

Aplicamos la máscara causal para impedir que cada token utilice información de palabras posteriores. Reemplazamos esas posiciones por $-\infty$, de modo que al aplicar softmax sus pesos de atención sean cero.

⑥ Matriz de atención

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Primera Fila: El

$$(0, -\infty, -\infty)$$

$$e^0 = 1$$

$$e^{-\infty} = 0$$

$$1 + 0 + 0 = 1$$

$$\left(\frac{1}{1}, \frac{0}{1}, \frac{0}{1} \right) =$$

$$(1, 0, 0)$$

Segunda Fila: banco

$$(0, 1, -\infty)$$

$$e^0 = 1$$

$$e^1 = 2,718$$

$$e^{-\infty} = 0$$

$$1 + 2,718 + 0 = 3,718$$

$$\frac{1}{3,718} = 0,269$$

$$\frac{2,718}{3,718} = 0,731$$

$$\frac{0}{3,718}$$

$$0 = 0$$

$$\frac{0}{3,718}$$

$$(0,269; 0,731; 0)$$

Tercera fila (apunta):

$$(0, 0, 500; 1)$$

$$e^0 = 1$$

$$e^{0.5} = 1.649$$

$$e^1 = 2.718$$

$$1 + 1.649 + 2.718 = 5.367$$

$$\frac{1}{5.367} = 0.186$$

$$\frac{1.649}{5.367} = 0.307 \quad (0.186; 0.307; 0.506)$$

$$\frac{2.718}{5.367} = 0.506$$

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0.269 & 0.731 & 0 \\ 0.186 & 0.307 & 0.506 \end{pmatrix}$$

Aplicamos softmax por fila para convertir las afinidades en pesos de atención entre 0 y 1, cuya suma es 1. Estos pesos indican cuánto influye cada palabra en la representación de cada token. Los valores $-\infty$ se transforman en cero, impidiendo atender a palabras futuras.

⑦ Mezcla

Primera fila: El $(1, 0, 0)$

$$1.0 + 0.1 + 0.1 = 0$$

$$1.0 + 0.1 + 0.0 = 0$$

$$1.0 + 0.0 + 0.1 = 0$$

$$1.1 + 0.1 + 0.2 = 1$$

$(0, 0, 1)$ Resultado

Segunda fila banco:

$$(0.269, 0.731, 0)$$

$$0.269 \cdot 0 + 0.731 \cdot 1 + 0 \cdot 1 = 0.731$$

$$0.269 \cdot 0 + 0.731 \cdot 1 + 0 \cdot 0 = 0.731$$

$$0.269 \cdot 0 + 0.731 \cdot 0 + 0 \cdot 1 = 0$$

$$0.269 \cdot 1 + 0.731 \cdot 1 + 0 \cdot 2 = 1$$

$$(0.731, 0.731, 0, 1)$$

Tercera fila: apuante

$$(0.186, 0.307, 0.506)$$

$$0.186(0) + 0.307 \cdot 1 + 0.506 \cdot (1) \\ = 0.307 + 0.506 = 0.813$$

$$0.186 \cdot 0 + 0.307 \cdot 1 + 0.506 \cdot 0 = 0.307$$

$$0.186 \cdot 0 + 0.307 \cdot 0 + 0.506 \cdot 1 = 0.506$$

$$0.186 \cdot 1 + 0.307 \cdot 1 + 0.506 \cdot 2 = 1.505$$

$$(0.814, 0.307, 0.506, 1.506)$$

Matriz AV final

$$AV = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0.731 & 0.731 & 0 & 1 \\ 0.814 & 0.307 & 0.506 & 1.506 \end{pmatrix}$$

Como la matriz de identidad W_0 al multiplicarla con AV no cambia los valores AV, $w_0 = AV$.

Multipliquemos la matriz de atención A por V para obtener una combinación ponderada de la información de cada palabra. Los pesos de atención determinan cuánto aporta cada token a la nueva representación.

Multipliquemos AV por W_O para proyectar la información combinada al espacio de salida de la atención.

⑧ Residual

Sumamos la matriz original X con la salida de atención

$$Z = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,814 & 0,307 & 0,506 & 1,506 \end{pmatrix}$$

Sumamos componente a componente

$$Z = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 1,814 & 0,307 & 1,506 & 3,506 \end{pmatrix}$$

La conexión residual suma la representación original X con la información obtenida mediante atención. Esto permite conservar la información inicial de cada palabra e incorporar su contexto.

⑨ Layer norm

Normalizamos cada fila de Z calculando su media y varianza

$$Z = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 1,814 & 0,307 & 1,506 & 3,506 \end{pmatrix}$$

$$\mu = \frac{\sum x_i}{4}, \quad \sigma^2 = \frac{\sum (x_i - \mu)^2}{4}$$

$$L_N(x) = \frac{x - \mu}{\sqrt{\sigma^2}}$$

Primera Fila: $(0, 0, 0, 2)$

$$M_1 = \frac{0+0+0+2}{4} = 0,500$$

$$\sigma_1^2 = \frac{3(0-0,5)^2 + (2-0,5)^2}{4} = 0,750$$

$$LN(z_1) = (-0,577; -0,577; -0,577; 1,732)$$

Segunda Fila: $(1,731; 1,731; 0; 2)$

$$M_2 = \frac{1,731 + 1,731 + 0 + 2}{4} = 1,366$$

$$\sigma_2^2 = \frac{2(1,731 - 1,366)^2 + (0 - 1,366)^2 + (2 - 1,366)^2}{4} \approx 0,633$$

$$LN(z_2) = (0,459; 0,459; -1,715; 0,797)$$

Tercera Fila: $(1,814; 0,307; 1,506; 3,506)$

$$M_3 = \frac{1,814 + 0,307 + 1,506 + 3,506}{4} = 1,783$$

$$\sigma_3^2 = \frac{(1,814 - 1,783)^2 + (0,307 - 1,783)^2 + (1,506 - 1,783)^2 + (3,506 - 1,783)^2}{4} \approx 1,306$$

$$LN(z_3) = (0,026, -1,292, -0,242, 1,507)$$

$$LN(z) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ 0,026 & -1,292 & -0,242 & 1,507 \end{pmatrix}$$

Ahora las representaciones mantienen la escala estable para la siguiente operación.

⑩ Feed - Forward

$$LN(\mathbf{z}) = \begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

Primera fila

(0, 0, 0, 0)

Segunda fila

(0, 0, 0, 0)

Tercera fila

(1.318, -1.318, 0, 0)

$$LN(\mathbf{z}) \cdot \mathbf{W}_1 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & -1.318 & 0 & 0 \end{pmatrix}$$

Aplicamos ReLU, que convierte los valores negativos en cero y mantiene los positivos:

$$ReLU(x) = \max(0, x)$$

$$ReLU(LN(\mathbf{z}) \mathbf{W}_1) = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 0 & 0 & 0 \end{pmatrix}$$

Como $\mathbf{W}_2$ es la matriz identidad, la multiplicación no modifica los valores.

$$FFN = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 0 & 0 & 0 \end{pmatrix}$$

Multiplicamos $LN(\mathbf{z}) \cdot \mathbf{W}_1$ para transformar las representaciones de cada palabra. Aplicamos ReLU para introducir no linealidad, eliminando los valores negativos.

Finalmente multiplicamos por W_2 pero no cambia el resultado. Esta operación reverte la dimensión física en la última palabra de la frase.

⑪ Residual

SUMAMOS la matriz Z del punto 8 con la matriz FFN.

$$H = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 1,814 & 0,307 & 1,506 & 3,506 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1,318 & 0 & 0 & 0 \end{pmatrix}$$

$$H = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 3,132 & 0,307 & 1,506 & 3,506 \end{pmatrix}$$

Sumamos la salida del FFN con Z . Esta conexión residual permite conservar la información obtenida mediante atención e incorporar las transformaciones realizadas por la red feed-forward.

⑫ Layer norm Final

Normalizamos cada fila de H

$$\mu = \frac{\sum x_i}{4}, \quad \sigma^2 = \frac{\sum (x_i - \mu)^2}{4}, \quad LN(x) = \frac{x - \mu}{\sqrt{\sigma^2}}$$

Primera fila: $(0, 0, 0, 2)$

$$\mu_1 = 0,500$$

$$\sigma_1^2 = 0,750$$

$$LN(H_1) = (-0,577; -0,577, -0,577, 1,732)$$

Segunda fila : (1,731; 1,731; 0; 2)

$$M_2 = 1,366$$

$$\sigma_2^2 \approx 0,633$$

$$LN(H_2) = (0,459; 0,459; -1,715; 0,797)$$

Tercera fila : (3.132, 0.307, 1.506, 3.506)

$$M_3 = 2.113$$

$$\sigma_3^2 \approx 1,652$$

$$LN(H_3) = (0,793, -1,405, -0,472, 1,084)$$

$$LN(H) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ 0,793 & -1,405 & -0,472 & 1,084 \end{pmatrix}$$

Normalizamos cada fila de H . Esto permite obtener representaciones con media cero y varianzas 1, manteniendo una escala estable antes de calcular la predicción de la siguiente palabra.

⑬ Predicción: logits y softmax

$$LN(H)_3 = (0,793, -1,405, -0,472, 1,084)$$

Multipliquemos por W_{out}

$$\text{logits} = (0,793, -1,405, -0,472, 1,084) \begin{pmatrix} 0 & 0 & 0 & 0 & 20 \\ 0 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Calculamos ^{un}logit por palabra:

$$E1 = 0$$

$$\text{banco} = 0$$

$$\text{apuesta} = -0,472(1) = -0,472$$

$$\text{presta} = -0,472 \cdot 1 = -0,472$$

$$\text{Peso} = 0.793 (2) = 1.586$$

$$\text{dinero} = -1.405 \cdot 2 = -2.810$$

$$\text{logits} = (0, 0, -0.472, -0.472, 1.586, -2.810)$$

$$P_i = \frac{e^{\text{logit}_i}}{\sum_j e^{\text{logit}_j}}$$

Palabra	Probabilidad
El	0.122
banco	0.122
apunta	0.076
Presta	0.076
Peso	0.596
dinero	0.007

Palabra predicha: Peso
 $P(\text{peso}) \approx 0.596 = 59.6\%$

La frase se completa como
 el banco apunta peso.

Multiplicamos la última fila de $\text{LN}(H)$ por Wout para obtener un puntaje (logit) para cada palabra del vocabulario. Luego aplicamos softmax para convertirlos en probabilidades. La palabra con mayor probabilidad es peso, con aproximadamente 59.6%.

Parte A Frase: "El banco presta -"

Se mantienen las justificaciones de la anterior frase)

1) Entrada: $X = E + P$

Embedding + posición

$$X_{el} = (0, 0, 0, 1) + (0, 0, 0, 0) = (0, 0, 0, 1)$$

$$X_{banco} = (1, 1, 0, 0) + (0, 0, 0, 1) = (1, 1, 0, 1)$$

$$X_{presta} = (0, 1, 1, 0) + (0, 0, 0, 2) = (0, 1, 1, 2)$$

$$X = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

Justificado en la frase anterior

2) Proyecciones $Q = X W_Q$ $K = X W_K$ $V = X W_V$

• Query (Q)

$$Q = X \cdot \underset{\text{en este caso}}{I} = X$$

en este caso $W_Q = \text{Identidad } (4 \times 4)$

$$Q = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

• Key (K)

$$\begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \} W_K$$

$$\underbrace{\begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}}_X \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{pmatrix}$$

$$K = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 0 & 0 \end{pmatrix}$$

• Value (V)

$$V = X \cdot \underset{\text{en este caso}}{I} = X$$

$$V = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

en este caso $W_V = \text{Identidad } (4 \times 4)$

3) Afinidades

$$S = Q \cdot K^T$$

$$\begin{pmatrix} 0 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix} \} K^T$$

$$\underbrace{\begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}}_Q \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

$$S = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix}$$

4) Escala $S/\sqrt{d}$

por consiguiente sabemos que $d=4$

$$S_{escala} = \frac{S}{\sqrt{4}} = \frac{1}{2} \begin{pmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix}$$

$$S_{escala} = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1.5 \\ 0 & 0.5 & 1 \end{pmatrix}$$

5) Máscara causal

$$S_{escala} \rightarrow S_{masked} = \begin{pmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 0.5 & 1 \end{pmatrix}$$

6) Matriz de atención $A = \text{softmax}$ por fila

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

• Primera fila ("El")

$$\left. \begin{array}{l} e^0 = 1 \quad e^{\infty} = 0 \quad e^{-\infty} = 0 \\ 1 + 0 + 0 = 1 \end{array} \right\} A_{El} = \left(\frac{1}{1}, \frac{0}{1}, \frac{0}{1} \right)$$

$$A_{El} = (1, 0, 0)$$

• Segunda fila ("banco")

$$\left. \begin{array}{l} e^0 = 1 \quad e^1 = e \approx 2.718 \quad e^{-\infty} = 0 \\ 1 + 2.718 = 3.718 \end{array} \right\} A_{banco} = \left(\frac{1}{3.718}, \frac{2.718}{3.718}, \frac{0}{3.718} \right)$$

$$A_{banco} = (0.269; 0.731; 0)$$

• Tercera fila ("Presla")

$$\left. \begin{array}{l} e^0 = 1 \quad e^{0.5} \approx 1.649 \quad e^1 = 2.718 \\ 1 + 1.649 + 2.718 = 5.367 \end{array} \right\} A_{Presla} = \left(\frac{1}{5.367}, \frac{1.649}{5.367}, \frac{2.718}{5.367} \right)$$

$$A_{Presla} = (0.186; 0.307; 0.506)$$

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0,269 & 0,731 & 0 \\ 0,186 & 0,307 & 0,506 \end{pmatrix}$$

7) Mezcla A V, y después la proyección de salida (AV) W₀

• Calculemos AV

$$\begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} \cdot V$$

$$\underbrace{\begin{pmatrix} 1 & 0 & 0 \\ 0,269 & 0,731 & 0 \\ 0,186 & 0,307 & 0,506 \end{pmatrix}}_A \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,813 & 0,506 & 1,505 \end{pmatrix}$$

$$AV \cdot W_0 = AV = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,813 & 0,506 & 1,505 \end{pmatrix}$$

En este caso W₀ = matriz de identidad (4x4)

8) Residual Z = X + (AV) W₀

$$Z = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 1 \\ 0,731 & 0,731 & 0 & 1 \\ 0,307 & 0,813 & 0,506 & 1,505 \end{pmatrix}$$

$$Z = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 1,813 & 1,506 & 3,505 \end{pmatrix}$$

9) Leyer norm LN(Z), fila por fila

$$LN(X_i) = \frac{X_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

Para la 1ª fila (EL)

$$\mu_{EL} = \frac{0+0+0+2}{4} = 0,5$$

$$\sigma_{EL}^2 = \frac{(0-0,5)^2 + (0-0,5)^2 + (0-0,5)^2 + (2-0,5)^2}{4}$$

$$\sigma_{EL}^2 = 0,75$$

$$\sigma_{EL} = \sqrt{0,75} \approx 0,866$$

Normalizamos cada componente:

$$\left(\frac{0-0,5}{0,866}, \frac{0-0,5}{0,866}, \frac{0-0,5}{0,866}, \frac{2-0,5}{0,866} \right)$$

$$= (-0,577; -0,577; -0,577; 1,732)$$

• Para a 2ª fila ("banco")

$$\mu_{\text{banco}} = \frac{1,731 + 1,731 + 0 + 2}{4} = 1,3655$$

$$\sigma^2_{\text{banco}} = \frac{(1,731 - 1,3655)^2 + (1,731 - 1,3655)^2 + (0 - 1,3655)^2 + (2 - 1,3655)^2}{4} \approx 0,634$$

$$\sigma_{\text{banco}} = \sqrt{0,634} \approx 0,796$$

Normalizamos cada componente:

$$\left(\frac{1,731 - 1,3655}{0,796}; \frac{1,731 - 1,3655}{0,796}; \frac{0 - 1,3655}{0,796}; \frac{2 - 1,3655}{0,796} \right)$$

$$= (0,459; 0,459; -1,715; 0,797)$$

• Para a 3ª fila ("pressão")

$$\mu_{\text{pressão}} = \frac{0,307 + 1,813 + 1,506 + 3,505}{4} = 1,78275$$

$$\sigma^2_{\text{pressão}} = \frac{(0,307 - 1,78275)^2 + (1,813 - 1,78275)^2 + (1,506 - 1,78275)^2 + (3,505 - 1,78275)^2}{4}$$

$$\sigma_{\text{pressão}} \approx \sqrt{1,30537} \approx 1,143$$

Normalizamos cada componente:

$$\left(\frac{0,307 - 1,78275}{1,143}; \frac{1,813 - 1,78275}{1,143}; \frac{1,506 - 1,78275}{1,143}; \frac{3,505 - 1,78275}{1,143} \right)$$

$$= (-1,292; 0,026; -0,242; 1,507)$$

$$LN(Z) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ -1,292 & 0,026 & -0,242 & 1,507 \end{pmatrix}$$

10) Feed-Forward $FFN = \text{ReLU}(\text{LN}(Z) W_1) W_2$

$$\begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ -1,292 & 0,026 & -0,242 & 1,507 \end{pmatrix} \begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} W_1$$

$\underbrace{\hspace{10em}}_{\text{LN}(Z)}$

$$\text{LN}(Z) \cdot W_1 = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1,318 & 1,318 & 0 & 0 \end{pmatrix}$$

Aplicamos $\text{ReLU}(x) = \max(0, x)$

$$\text{ReLU} \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ -1,318 & 1,318 & 0 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,318 & 0 & 0 \end{pmatrix}$$

en ReLU si la entrada ≤ 0 queda 0,
 sino se deja el número que estaba
 solo se queda con los positivos

$$FFN = \text{ReLU}(\text{LN}(Z) W_1) W_2 = \text{ReLU}(\text{LN}(Z) W_1)$$

matriz de identidad en este caso, por ende queda igual

$$FFN = \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,318 & 0 & 0 \end{pmatrix}$$

11) Residual $H = Z + FFN$

$$H = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 1,813 & 1,506 & 3,505 \end{pmatrix} + \begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1,318 & 0 & 0 \end{pmatrix}$$

$$H = \begin{pmatrix} 0 & 0 & 0 & 2 \\ 1,731 & 1,731 & 0 & 2 \\ 0,307 & 3,131 & 1,506 & 3,505 \end{pmatrix}$$

12) Layer norm Final LN(H)

• Primera Fila:

$$\mu_1 = \frac{0+0+0+2}{4} = 0,5$$

$$\sigma_1^2 = \frac{3(0-0,5)^2 + (2-0,5)^2}{4} = 0,75$$

$$\sigma_1 = \sqrt{0,75} = 0,866$$

Normalizamos: $\left(\frac{0-0,5}{0,866} ; \frac{0-0,5}{0,866} ; \frac{0-0,5}{0,866} ; \frac{2-0,5}{0,866} \right)$

$$= (-0,577 ; -0,577 ; -0,577 ; 1,732)$$

• Segunda Fila:

$$\mu_2 = \frac{(1,731) \cdot 2 + 0 + 2}{4} = 1,3655$$

$$\sigma_2^2 = \frac{2 \cdot (1,731 - 1,3655)^2 + (0 - 1,3655)^2 + (2 - 1,3655)^2}{4}$$

$$\sigma_2 \approx \sqrt{0,634} \approx 0,796$$

Normalizamos: $\left(\frac{1,731 - 1,3655}{0,796} ; \frac{1,731 - 1,3655}{0,796} ; \frac{0 - 1,3655}{0,796} ; \frac{2 - 1,3655}{0,796} \right)$

$$= (0,459 ; 0,459 ; -1,715 ; 0,797)$$

• Tercera Fila

$$\mu_3 = \frac{0,307 + 3,131 + 1,506 + 3,505}{4} = 2,11225$$

$$\sigma_3^2 = \frac{(0,307 - 2,112)^2 + (3,131 - 2,112)^2 + (1,506 - 2,112)^2 + (3,505 - 2,112)^2}{4}$$

$$\sigma_3 \approx \sqrt{1,651} \approx 1,285$$

Normalizamos: $\left(\frac{0,307 - 2,112}{1,285} ; \frac{3,131 - 2,112}{1,285} ; \frac{1,506 - 2,112}{1,285} ; \frac{3,505 - 2,112}{1,285} \right)$

$$= (-1,405 ; 0,793 ; -0,472 ; 1,084)$$

$$LN(H) = \begin{pmatrix} -0,577 & -0,577 & -0,577 & 1,732 \\ 0,459 & 0,459 & -1,715 & 0,797 \\ -1,405 & 0,793 & -0,472 & 1,084 \end{pmatrix}$$

13) Predicción con la última Fil. de $LN(H)$,
Logits = Fil. W_{out} y aplicar softmax

Calculamos Logits

$$h = (-1,405 ; 0,793 ; -0,472 ; 1,084)$$

$$L = h \cdot W_{out} \quad W_{out} = \begin{pmatrix} 0 & 0 & 0,02 & 0 \\ 0 & 0 & 0,00 & 0 \\ 0 & 0 & 1,10 & 0 \\ 0 & 0 & 0,00 & 0 \end{pmatrix}$$

$$L_{el} = 0 + 0 + 0 + 0 = 0$$

$$L_{banco} = 0 + 0 + 0 + 0 = 0$$

$$L_{guardia} = 0 + 0 + 1 \cdot (-0,472) + 0 = -0,472$$

$$L_{presta} = 0 + 0 + 1 \cdot (-0,472) + 0 = -0,472$$

$$L_{peso} = 2 \cdot (-1,405) + 0 + 0 + 0 = -2,81$$

$$L_{dinero} = 0 + 2 \cdot 0,793 + 0 + 0 = 1,586$$

$$L = (0; 0; -0,472; -0,472; -2,81; 1,586)$$

Aplicamos Softmax $P_i = \frac{e^{L_i}}{\sum_{k=1}^6 e^{L_k}}$

$$e^0 = 1 ; e^{-0,472} \approx 0,624 ; e^{-2,81} \approx 0,060 ; e^{1,586} \approx 4,884$$

$$D = 1 + 1 + 0,624 + 0,624 + 0,06 + 4,884 = 8,192$$

$$P_1 = \frac{1}{8,192} = 0,122 ; P_2 = 0,122 ; P_3 = \frac{0,624}{8,192} = 0,076 ; P_4 = 0,076 ; P_5 = \frac{0,06}{8,192} = 0,007$$

$$P_6 = \frac{4,884}{8,192} = 0,596$$

$$P = (0,122; 0,122; 0,076; 0,076; 0,007; 0,596)$$

La mayor probabilidad corresponde a dinero
con un 59,6%

"El banco presta dinero"

Parte B: Atención sin máscara (Encoder)

⑤ sin máscara causal

En el encoder no se aplica máscara causal, por lo que cada palabra puede atender a todas las demás, incluso las posteriores.

Para ambas frases:

$$S/2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 1 & 1,500 \\ 0 & 0,500 & 1 \end{pmatrix}$$

No reemplazamos ningún valor por $-\infty$, ya que el encoder utiliza el contexto completo.

⑥ Matriz de atención softmax

Para ambas frases

$$A = \begin{pmatrix} 0,333 & 0,333 & 0,333 \\ 0,122 & 0,332 & 0,547 \\ 0,186 & 0,307 & 0,506 \end{pmatrix}$$

Aplicamos softmax por Fila.

$$\text{softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

Primera fila

$$e^0 = e^0 = e^0 = 1$$

$$A_1 = (1/3, 1/3, 1/3)$$

Segunda fila

$$D_2 = e^0 + e^1 + e^{1,5} = 8,200$$

$$A_2 = (1/8,200, 2,718/8,200, 4,482/8,200)$$

$$A_2 = (0,122, 0,332, 0,547)$$

Tercera fila

$$D_3 = e^0 + e^{0,5} + e^1 = 5,367$$

$$A_3 = (1/5,367, 1,649/5,367, 2,718/5,367)$$

$$A_3 = (0,186, 0,307, 0,506)$$

7) Mezcla

Frase 1: El bardo apuana

$$V_a = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{pmatrix}$$

Calculamos AV_a multiplicando filas de A por columnas de V.

$$A \cdot V_a = \begin{pmatrix} 0.667 & 0.333 & 0.333 & 1.333 \\ 0.878 & 0.332 & 0.547 & 1.547 \\ 0.814 & 0.307 & 0.506 & 1.506 \end{pmatrix}$$

Frase 2: El bardo presta

$$V_p = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix}$$

$$A \cdot V_p = \begin{pmatrix} 0.333 & 0.667 & 0.333 & 1.333 \\ 0.332 & 0.878 & 0.547 & 1.547 \\ 0.307 & 0.814 & 0.506 & 1.506 \end{pmatrix}$$

Como $W_0 = I$, en ambas Frases:

$$(AV)W_0 = AV$$

Multiplicamos A por V para mezclar^{la} información de los tokens según sus pesos de atención. La proyección de salida no cambia el resultado porque W_0 es identidad.

Parte 8 Residual $z = X + (AV)$ wo

Frase 1: El banco aqueña

$$Z_a = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0,667 & 0,333 & 0,333 & 1,333 \\ 0,878 & 0,332 & 0,547 & 1,547 \\ 0,814 & 0,307 & 0,506 & 1,506 \end{pmatrix}$$

$$Z_a = \begin{pmatrix} 0,667 & 0,333 & 0,333 & 2,333 \\ 1,878 & 1,332 & 0,547 & 2,547 \\ 1,814 & 0,307 & 1,506 & 3,506 \end{pmatrix}$$

Frase 2: El banco presta

$$Z_p = \begin{pmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{pmatrix} + \begin{pmatrix} 0,333 & 0,667 & 0,333 & 1,333 \\ 0,332 & 0,878 & 0,547 & 1,547 \\ 0,307 & 0,814 & 0,506 & 1,506 \end{pmatrix}$$

$$Z_p = \begin{pmatrix} 0,333 & 0,667 & 0,333 & 2,333 \\ 1,332 & 1,878 & 0,547 & 2,547 \\ 0,307 & 1,814 & 1,506 & 3,506 \end{pmatrix}$$

9) Layer Norm, $LN(z)$

$$\mu = \frac{\sum x_i}{4} \quad \sigma^2 = \frac{\sum (x_i - \mu)^2}{4} \quad LN = \frac{x - \mu}{\sqrt{\sigma^2}}$$

El banco aqueña

primera fila

$$\mu_1 = \frac{0,667 + 0,333 + 0,333 + 2,333}{4} = 0,917$$

$$\sigma_1^2 = \frac{(0,667 - 0,917)^2 + 2(0,333 - 0,917)^2 + (2,333 - 0,917)^2}{4}$$

$$\sigma \approx \sqrt{0,688}$$

$$LN(Z_1) = (-0,302; -0,704; -0,704; 1,709)$$

Segunda fila

$$\mu_2 = \frac{1,878 + 1,332 + 0,547 + 2,547}{4} = 1,576$$

$$\sigma_2^2 = \frac{(1,878 - 1,576)^2 + (1,332 - 1,576)^2 + (0,547 - 1,576)^2 + (2,547 - 1,576)^2}{4}$$

$$\sigma_2 \approx \sqrt{0,536}$$

$$LN(\bar{z}_2) = (0,412 ; -0,333 ; -1,403 ; 1,323)$$

Terceira fila

$$\mu_3 = \frac{1,814 + 0,307 + 1,506 + 3,506}{4} = 1,783$$

$$\sigma_3^2 = \frac{(1,814 - 1,783)^2 + (0,307 - 1,783)^2 + (1,506 - 1,783)^2 + (3,506 - 1,783)^2}{4}$$

$$\sigma_3 \approx \sqrt{1,306}$$

$$LN(\bar{z}_3) = (0,026 ; -1,292 ; -0,242 ; 1,507)$$

$$LN(\bar{z}_2) = \begin{pmatrix} -0,302 & -0,704 & -0,704 & 1,709 \\ 0,412 & -0,333 & -1,403 & 1,323 \\ 0,026 & -1,292 & -0,242 & 1,507 \end{pmatrix}$$

Frase 2: El banco presta

Primera fila

$$\mu_1 = \frac{0,333 + 0,667 + 0,333 + 2,333}{4} = 0,917$$

$$\sigma_1^2 = \frac{2(0,333 - 0,917)^2 + (0,667 - 0,917)^2 + (2,333 - 0,917)^2}{4}$$

$$LN(\bar{z}_1) = (-0,704 ; -0,302 ; 0,704 ; 1,709)$$

Segunda fila

$$\mu_2 = \frac{1,332 + 1,878 + 0,547 + 2,547}{4} = 1,576$$

$$\sigma_2^2 = \frac{(1,332 - 1,576)^2 + (1,878 - 1,576)^2 + (0,547 - 1,576)^2 + (2,547 - 1,576)^2}{4}$$

$$\sigma_2 \approx \sqrt{0,536}$$

$$LN(\bar{z}_2) = (-0,333 ; 0,412 ; -1,463 ; 1,323)$$

Tercera fila:

$$\mu_3 = \frac{0,307 + 1,814 + 1,506 + 3,506}{4} = 1,783$$

$$\sigma_3^2 = \frac{(0,307 - 1,783)^2 + (1,814 - 1,783)^2 + (1,506 - 1,783)^2 + (3,506 - 1,783)^2}{4}$$

$$\sigma_3 \approx \sqrt{1,306}$$

$$LN(\bar{z}_3) = (-1,292 ; 0,026 ; -0,242 ; 1,507)$$

$$LN(\bar{z}_p) = \begin{pmatrix} -0,704 & -0,302 & -0,704 & 1,709 \\ -0,333 & 0,412 & -1,463 & 1,323 \\ -1,292 & 0,026 & -0,242 & 1,507 \end{pmatrix}$$

Comparación de la fila de banco:

- El banco espera: $LN(\bar{z}_a)_{\text{banco}} =$

- El banco presta: $LN(\bar{z}_p)_{\text{banco}} = (-0,333 ; 0,412 ; -1,463 ; 1,323)$

El vector de banco cambia según la frase. Con
aquella predomina la dimensión Física, mientras que
con presta predomina la Financiera. Esto sucede porque
el encoder permite que banco atienda a las
palabras posteriores.

Preguntas:

- 1) En la parte A, el vector de banco es igual en ambas frases: $(0,459 ; 0,459 ; -1,715 ; 0,797)$. En la parte B cambia porque el encoder permite que banco atienda a las palabras posteriores, incorporando información de cuánto o presta.
- 2) El modelo sabe predecir peso o dinero porque la predicción se hace utilizando el vector de la última palabra, que es diferente en cada frase. Este vector incorpora el contexto anterior y permite distinguir si corresponde predecir peso o dinero.
- 3) Las predicciones de la parte A y de la parte B son iguales porque en la última posición no hay palabras posteriores que bloquear. Por lo tanto, la máscara causal no modifica su atención y, usando las mismas operaciones restantes se obtiene la misma predicción.

④ La parte A se parece a GPT (decoder), que utiliza atención causal para generar texto prediciendo el siguiente token. La parte B se parece a BERT (encoder), que utiliza atención bidireccional para comprender el contexto y realizar tareas como clasificación de textos.

⑤ Cambiarían los vectores de entrada y algunos resultados, porque se perdería la información explícita de posición. En frases donde el orden cambia el sentido, un encoder sin posiciones ~~no~~ no podría distinguir adecuadamente ese orden; un decoder conservaría cierta información del orden, gracias a la máscara causal.